

基于数据驱动的动力电池健康状态估计和剩余寿命预测方法研究

Research on Data-Driven Approaches for State of Health
Estimation and Remaining Useful Life Prediction of Lithium-Ion
Batteries in Electric Vehicles

答辩人：林新辉

导师：李沂洹

控制与计算机工程学院，华北电力大学

2023年6月13日

目录

① 研究背景和研究对象

② 建模和实验

③ 总结和展望

④ 写在最后






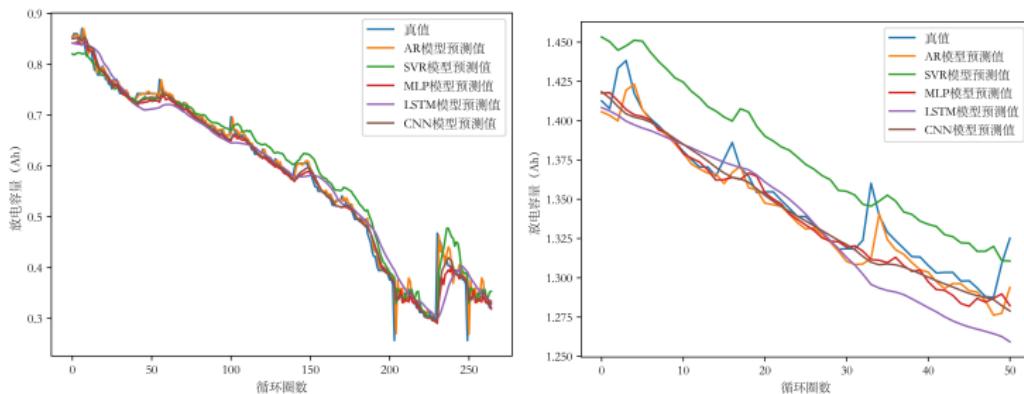
图 1: 电池 SOH、RUL 和 SOC 示意图

SOH 电池健康状态，使用电池放电容量表征，描述电池性能退化状态， $SOH = \frac{Q_{max}}{Q_{nominal}} \times 100\%$

RUL 电池剩余寿命，描述电池从当前循环到寿命终止（EOL）循环的过程， $RUL = n_{EOL} - n_{current}$

SOC 电池荷电状态，和 SOH 有相同的形式，描述电池电荷量， $SOC = \frac{Q_{remain}}{Q_{max}} \times 100\%$

基于电池容量历史退化数据的 SOH 估计



(a) CALCE_CS2_35 电池上的 SOH 估计结果 (b) NASA_PCoE_B0005 电池上的 SOH 估计结果

图 2: 五种模型的 SOH 估计结果示意图

- 在 CALCE 数据集（包含 4 颗电池的循环数据）和 NASA PCoE 数据集（包含 4 颗电池的循环数据）上开展实验，采用留一法划分数据集
- 受篇幅限制，展示在 CALCE_CS2_35 电池和 NASA_PCoE_B0005 电池上的测试结果

基于电池容量历史退化数据的 SOH 估计

评价指标	CALCE 数据集					NASA PCoE 数据集				
	AR	SVR	MLP	LSTM	CNN	AR	SVR	MLP	LSTM	CNN
平均 MaxE	0.116	0.141	0.147	0.152	0.142	0.054	0.097	0.111	0.158	0.113
平均 MAE	0.010	0.023	0.009	0.028	0.008	0.008	0.033	0.019	0.041	0.020
平均 RMSE	0.016	0.028	0.014	0.035	0.013	0.013	0.037	0.026	0.057	0.027

表 1: 五种模型预测性能评估结果

- 五个模型均取得较高预测精度，使用数据驱动方法实现锂离子电池 SOH 估计具有可行性
- 对于短期时间序列预测问题，非隐状态模型（AR、SVR、MLP 和 CNN）的预测精度优于隐状态模型（LSTM）

基于电池充放电直接测量量的 SOH 估计




图 3: CNN 模型在四种不同训练配置下 SOH 估计结果示意图

- 在 TRI 数据集（包含 16 块电池的循环数据，均分为四组）上进行实验
- 受篇幅限制，展示其中编号为 b3c0 的电池在四种不同实验配置下的测试结果

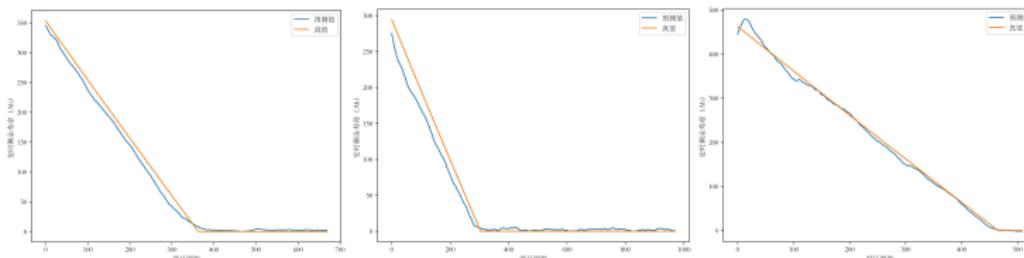
评价指标	VIT 输入, 无变换	VIT 输入, 有变换	VIq 输入, 无变换	VIq 输入, 有变换
平均 MaxE	0.110514	0.131351	0.08509	0.068284
平均 MAE	0.011018	0.015671	0.006605	0.006807
平均 RMSE	0.016167	0.021842	0.010835	0.009845
模型参数量	60421	12693	60421	12693

表 2: 四组实验 CNN 模型 SOH 评估结果

- 对比使用 V 、 I 、 T 为输入的情形，使用 V 、 I 、 q 为输入时模型预测性能有显著提升
- 使用时间序列-图像变换能在保持预测精度的前提下显著降低模型参数量



电池 RUL 预测



(a) 电池 044 的 RUL 预测结果 (b) 电池 039 的 RUL 预测结果 (c) 电池 041 的 RUL 预测结果

图 4: DeepLSTM 模型的 RUL 预测结果示意图

- 在 Unibo Powertools 数据集（包含 27 块电池的循环数据）上进行实验，其中 20 块电池数据用作训练集、7 块电池数据被用作测试集
- 受篇幅限制，展示在编号为 044、039 和 041 的电池上的测试结果

电池 RUL 预测

评价指标	电池 003	电池 011	电池 013	电池 006	电池 044	电池 039	电池 041	均值
RMSE	3.855191	3.102227	10.77393	10.12258	13.87137	8.883196	4.498271	7.872395
NRMSE	0.035861	0.02924	0.181346	0.028673	0.047128	0.019219	0.051681	0.056164

表 3: DeepLSTM 模型电池 Ah-RUL 预测性能

- 实验结果表明使用数据驱动方法实现锂离子电池 RUL 预测具有可行性



- 总结


- 基于电池容量历史退化数据实现 SOH 估计，比较五种模型的预测性能
- 基于电池充放电直接测量量实现 SOH 估计，使用电荷量取代电池表面温度作为模型输入提高预测性能，使用时间序列-图像变换减少模型参数量
- 基于电池充放电直接测量量实现 RUL 预测，提出依据容量定义的 Ah-RUL 取代依据循环圈数定义的 cycle-RUL

- 展望

- 估计/预测模型改进
 - 研究融合模型，提高预测性能
 - 引入贝叶斯方法，实现对预测结果的不确定性度量以更好支持工业决策
 - 引入迁移学习策略，提高模型泛化能力
- 模型在嵌入式平台的部署：模型量化和模型转换

代码可用性

本课题相关代码已在 `github` 上开源, 请见:
https://github.com/hilinxinhui/battery_phm.git



汇报完毕，请各位老师批评指正！